

Rapport d'avancement

Analyse et préparation des données

Projet de prédiction de la réhospitalisation à 3 mois

Préparation de la base de données IC-FEr

Réalisé par : Ismail Makhloufi

Encadrante : Imen Ben Said

6 juillet 2026

Table des matières

1	Objectif du rapport	3
2	Description de la base	3
3	Nettoyage initial	3
3.1	Suppression des colonnes vides	3
3.2	Suppression des variables de suivi	4
4	Analyse de corrélation avec la cible	4
4.1	Interprétation	5
5	Analyse de redondance entre variables explicatives	5
5.1	Méthode de décision	5
6	Variables dérivées	5
7	Détection des valeurs aberrantes	6
7.1	Méthode utilisée	6
7.2	Résultats principaux	6
7.3	Interprétation	7
7.4	Valeurs médicalement suspectes	7
8	Variables constantes et presque constantes	7
8.1	Variables constantes	7
8.2	Variables presque constantes	7
9	Analyse des valeurs manquantes	8
9.1	Interprétation	8
10	Problèmes et ambiguïtés identifiés	9
10.1	Valeurs extrêmes statistiques	9
10.2	Valeurs médicalement suspectes	9
10.3	Variables presque constantes	9
10.4	Variables très manquantes	9
10.5	Redondance entre variables	10
11	Solutions proposées	10
11.1	Pour les valeurs aberrantes	10
11.2	Pour les variables presque constantes	10
11.3	Pour les variables très manquantes	10
11.4	Pour l'imputation	10

12 Prochaine étape	11
13 Conclusion	11

1 Objectif du rapport

Ce rapport présente l'état d'avancement de la préparation de la base de données avant la construction du modèle prédictif. L'objectif est de produire une base propre, cohérente et exploitable pour prédire la réhospitalisation à 3 mois chez les patients atteints d'insuffisance cardiaque à fraction d'éjection réduite.

Les étapes réalisées concernent principalement :

- le nettoyage initial de la base ;
- la suppression des variables non exploitables ou générant une fuite de données ;
- l'analyse de corrélation ;
- l'étude de la redondance entre variables ;
- la détection des valeurs aberrantes ;
- l'identification des variables constantes et presque constantes ;
- l'analyse des valeurs manquantes ;
- la préparation des décisions à valider médicalement.

2 Description de la base

La base initiale contient 251 patients et 176 variables. La variable cible utilisée pour le modèle est `rehospit_3_mois`.

Élément	Résultat
Nombre de patients	251
Nombre initial de variables	176
Variable cible	<code>rehospit_3_mois</code>
Patients non réhospitalisés à 3 mois	195
Patients réhospitalisés à 3 mois	56
Taux de réhospitalisation	environ 22%

TABLE 1 – Description générale de la base initiale

Le dataset présente donc un déséquilibre modéré entre les deux classes. Ce point devra être pris en compte lors de la modélisation.

3 Nettoyage initial

3.1 Suppression des colonnes vides

Quatre colonnes totalement vides ont été supprimées, car elles ne contenaient aucune information exploitable.

- `biologie_admission`
- `ECG_admission`
- `parametres_ETT`

— TTT_de_sortie

3.2 Suppression des variables de suivi

Les variables correspondant au suivi après l'hospitalisation ou à des événements futurs ont été supprimées afin d'éviter une fuite de données.

Ces variables ne doivent pas être utilisées pour prédire la réhospitalisation à 3 mois, car elles peuvent contenir une information postérieure à la période de prédiction.

Exemples de variables supprimées :

— cons_4s__3mois
 — PAS_controle
 — PAD_controle
 — congestion_residuelle
 — dyspnee_NYHA
 — creat_3mois
 — optimisation_ttt
 — rehospit_6mois
 — mortalitÃl_6mois
 — rehospit_1annÃle
 — mortalitÃl_1annÃle

Après cette étape, la base contenait 251 patients et 148 variables.

4 Analyse de corrélation avec la cible

Une analyse de corrélation a été réalisée entre les variables explicatives numériques et la variable cible `rehospit_3_mois`. L'objectif était d'identifier les variables ayant une association linéaire avec la réhospitalisation à 3 mois.

Variable	Corrélation avec la cible
cause_valvulaire	+0.298
RRS	-0.253
OG	+0.236
RAo	+0.209
statine	-0.208
PAS	-0.208
REE	+0.205
ATCD_d_hospitalisation	+0.200

TABLE 2 – Variables les plus corrélées avec la réhospitalisation à 3 mois

4.1 Interprétation

Les corrélations observées sont faibles à modérées. La plus forte corrélation est proche de 0.30. Cela indique que la réhospitalisation à 3 mois ne dépend probablement pas d'une seule variable, mais d'une combinaison de plusieurs facteurs cliniques, biologiques, échographiques et thérapeutiques.

Cette analyse est donc utilisée comme une étape exploratoire. Une variable faiblement corrélée ne doit pas être supprimée automatiquement, car elle peut être utile dans un modèle non linéaire ou en interaction avec d'autres variables.

5 Analyse de redondance entre variables explicatives

Une matrice de corrélation entre variables explicatives a été utilisée pour détecter les variables fortement redondantes. Un seuil de corrélation absolue supérieur à 0.85 a été retenu.

Variable 1	Variable 2	Corrélation
Hb	IC	0.996
ASAT	ALAT	0.993
CHOL	LDL	0.936
RRS	espace_PR	0.936
GB	PNN	0.932
FA	RRS	0.926
SIV	PP	0.852

TABLE 3 – Principales paires de variables fortement corrélées

5.1 Méthode de décision

La suppression des variables redondantes ne s'est pas basée uniquement sur la corrélation statistique. Trois critères ont été pris en compte :

- la corrélation avec la variable cible ;
- le taux de valeurs manquantes ;
- l'importance et l'interprétabilité médicale.

Certaines variables ont été considérées comme redondantes d'un point de vue statistique, mais nécessitent une validation médicale avant suppression définitive.

6 Variables dérivées

Une attention particulière a été portée aux variables dérivées. Le cas principal concerne le poids, la taille et l'IMC.

L'IMC est défini par :

$$IMC = \frac{poids}{taille^2}$$

Lorsque l'IMC est présent et correctement calculé, le poids et la taille peuvent être considérés comme redondants pour une première version du modèle. Cependant, le poids et la taille peuvent aussi être utiles pour vérifier la cohérence de l'IMC.

7 Détection des valeurs aberrantes

7.1 Méthode utilisée

Deux méthodes complémentaires ont été utilisées :

- une méthode statistique basée sur l'IQR ;
- des règles médicales simples pour détecter les valeurs impossibles ou fortement suspectes.

La méthode IQR utilise les bornes suivantes :

$$Borne\ infrieure = Q1 - 1.5 \times IQR$$

$$Borne\ suprieure = Q3 + 1.5 \times IQR$$

Une valeur située en dehors de ces bornes est considérée comme extrême sur le plan statistique.

7.2 Résultats principaux

Les variables ayant le plus de valeurs extrêmes selon la méthode IQR sont présentées ci-dessous.

Variable	Nombre d'outliers	Pourcentage
dose_de_lasilix	43	17.13%
troponine	37	14.74%
dose_cum_24h_lasilixIV_mg	32	12.75%
ASAT	22	8.76%
IEC_dose	22	8.76%
duree_hospitalisation_jour	21	8.37%
CRP	21	8.37%
creat	17	6.77%
Uree	17	6.77%

TABLE 4 – Variables avec le plus de valeurs extrêmes selon l'IQR

7.3 Interprétation

Les valeurs extrêmes statistiques ne sont pas nécessairement des erreurs. Dans un contexte médical, une valeur très élevée de troponine, CRP, créatinine, urée ou dose de Lasilix peut être réelle et traduire la gravité clinique du patient.

Ces valeurs doivent donc être discutées médicalement avant toute correction ou suppression.

7.4 Valeurs médicalement suspectes

En complément de l'IQR, certaines valeurs ont été identifiées comme médicalement impossibles ou fortement suspectes.

Index patient	Variable	Valeur observée	Décision proposée
195	PAD	8	Vérifier ou remplacer par manquant
59	IMC	444.44	Corriger à partir du poids et de la taille
103	FEVG	593	Vérifier ou remplacer par manquant
149	ASAT	21308	Vérifier ou remplacer par manquant

TABLE 5 – Valeurs médicalement suspectes détectées

8 Variables constantes et presque constantes

8.1 Variables constantes

Aucune variable totalement constante n'a été détectée. Par conséquent, aucune colonne n'a été supprimée automatiquement à cette étape.

Type de variable	Nombre détecté
Variables constantes	0
Variables supprimées automatiquement	0

TABLE 6 – Résultat de la détection des variables constantes

8.2 Variables presque constantes

Les variables presque constantes sont les variables pour lesquelles une modalité représente au moins 98% des patients. Elles sont rares, mais peuvent avoir un intérêt médical.

Variable	Type	Modalité majoritaire
hÃlpathopathie	binaire	99.20%
hyperthyroïdie	binaire	98.01%

atcds_dmpc	binaire	99.60%
pontage_aorto_coronaire	binaire	98.01%
cause_CMH	binaire	99.20%
recours_HD	binaire	99.60%
bloc_trifasiculaire	binaire	98.40%
fuite_para_prothetique_mitrale	binaire	98.41%
fuite_para_prothetique_aortique	numérique	99.60%
ezebib10	binaire	99.60%
moxonidine	binaire	99.20%
vastarel	binaire	98.80%
OLD	binaire	98.80%

TABLE 7: Variables presque constantes détectées

Ces variables n'ont pas été supprimées automatiquement. Elles doivent être discutées avec le médecin afin de décider si elles doivent être conservées ou supprimées.

9 Analyse des valeurs manquantes

Une analyse des valeurs manquantes a été réalisée sur la base actuelle de 251 patients et 138 variables.

Variable	Valeurs manquantes	Pourcentage	Décision provisoire
TDE	191	76.10%	À discuter
ProBNP	187	74.50%	À discuter
HBA1c	159	63.35%	À discuter
ITv_ss_AO	156	62.15%	À discuter
ferritinemie	140	55.78%	À discuter
A	123	49.00%	À discuter
CPK	123	49.00%	À discuter
TSH	121	48.21%	À discuter
Eprime	103	41.04%	À discuter
E	81	32.27%	Garder avec prudence

TABLE 8: Variables avec le plus de valeurs manquantes

9.1 Interprétation

Les variables avec plus de 60% de valeurs manquantes sont :

- TDE
- ProBNP
- HBA1c

— ITv_ss_A0

Ces variables ne doivent pas être supprimées automatiquement. Certaines peuvent avoir une importance médicale malgré leur taux élevé de valeurs manquantes. C'est notamment le cas de `ProBNP`, qui est un marqueur important dans l'insuffisance cardiaque.

10 Problèmes et ambiguïtés identifiés

Plusieurs points nécessitent une validation médicale avant de passer à la modélisation finale.

10.1 Valeurs extrêmes statistiques

Certaines variables présentent un nombre important de valeurs extrêmes selon l'IQR, comme `dose_de_lasilix`, `troponine`, `CRP`, `creat` ou `Uree`. Cependant, ces valeurs peuvent être médicalement plausibles.

Problème : la méthode statistique seule ne permet pas de savoir si une valeur est fausse ou simplement liée à un patient grave.

10.2 Valeurs médicalement suspectes

Certaines valeurs semblent impossibles ou très suspectes, par exemple :

- `PAD` = 8
- `IMC` = 444.44
- `FEVG` = 593
- `ASAT` = 21308

Problème : il faut savoir si ces valeurs peuvent être corrigées à partir du dossier patient ou si elles doivent être remplacées par des valeurs manquantes.

10.3 Variables presque constantes

Certaines variables sont très rares dans la base. Elles peuvent être peu utiles statistiquement, mais importantes médicalement.

Problème : une suppression automatique risque d'éliminer une information clinique rare mais pertinente.

10.4 Variables très manquantes

Certaines variables présentent plus de 60% de valeurs manquantes.

Problème : supprimer ces variables peut améliorer la stabilité du modèle, mais peut aussi supprimer une information médicale importante.

10.5 Redondance entre variables

Certaines variables sont fortement corrélées entre elles, mais ne portent pas toujours exactement la même signification clinique.

Problème : le choix de la variable à conserver doit tenir compte de l'interprétation médicale, et pas seulement du critère statistique.

11 Solutions proposées

11.1 Pour les valeurs aberrantes

Je propose de distinguer deux types de valeurs :

- **valeurs extrêmes mais plausibles :** à conserver après validation médicale ;
- **valeurs impossibles ou fortement suspectes :** à corriger si la vraie valeur est retrouvée, sinon à remplacer par une valeur manquante.

11.2 Pour les variables presque constantes

Je propose de ne pas les supprimer automatiquement. Elles doivent être présentées à le médecin avec la question suivante :

Ces variables sont très rares dans la base. Ont-elles une importance clinique suffisante pour être conservées dans le modèle, ou peut-on les supprimer pour réduire la dimension ?

11.3 Pour les variables très manquantes

Je propose une stratégie en deux versions :

- **Versión prudente :** conserver les variables importantes même si elles sont très manquantes, ajouter un indicateur de valeur manquante, puis imputer.
- **Versión réduite :** supprimer les variables validées comme non indispensables médicalement et trop incomplètes.

Pour les variables comme ProBNP, je propose de ne pas supprimer immédiatement.

11.4 Pour l'imputation

Après validation médicale, je propose l'approche suivante :

- variables numériques : imputation par la médiane ;
- variables binaires : imputation par le mode ;
- variables catégorielles : imputation par le mode ;
- variables très importantes mais très manquantes : ajout d'un indicateur de valeur manquante.

12 Prochaine étape

La prochaine étape consiste à valider avec l'encadrante médicale :

1. les valeurs aberrantes à corriger ou remplacer ;
2. les variables presque constantes à conserver ou supprimer ;
3. les variables très manquantes à garder ou supprimer ;
4. la stratégie d'imputation finale.

Après cette validation, la base finale pourra être préparée pour l'entraînement des premiers modèles prédictifs.

13 Conclusion

Cette phase a permis de préparer progressivement la base de données avant la modélisation. Les colonnes vides et les variables de suivi futur ont été supprimées afin d'éviter les fuites de données. Les analyses de corrélation, de redondance, de valeurs aberrantes, de variables presque constantes et de valeurs manquantes ont permis d'identifier les principaux points à traiter.

La principale conclusion est que plusieurs décisions ne doivent pas être prises automatiquement. Dans un contexte médical, certaines valeurs extrêmes ou variables rares peuvent être importantes. La validation médicale est donc indispensable avant de finaliser la base de données et de passer à l'étape de modélisation.